

# SmartReview

## Machine Learning for Customer Review Analysis

Soutenance Flash — Step 7 : Publication & Dissémination

Réalisé par : AIDI Omaïma · ELMOUSSAOUI Fatima

Encadrant : Prof. Mohamed EL HAJJI

Module : Méthodologie de recherche | Master BD & IA — Temps aménagé

Parcours Steps 1 → 7 · De la problématique à la publication

# Abstract — En une slide

- Contexte : automatiser la polarité (+/-) des avis clients (NLP + ML).
- Méthode : benchmark contrôlé NB / LR / SVM / RF sur IMDb 50K + TF-IDF (5 000, uni+bi).
- Design : split 80/20 stratifié, random\_state=42, CV 5-fold, ablation prétraitement NLP.
- Résultat clé : Logistic Regression — F1 = 0.889 · Accuracy = 88.71 % · ~1.8 s.
- Hypothèses : H1 nuancée · H2 partielle · H3 confirmée (compromis perf / temps).
- Livrable : manuscript IEEE + fiche canal (ICMLA) + démo Streamlit SmartReview Lite.

# Step 1 — Problématique & question de recherche

STEP 1

## Contexte & enjeu

- Explosion des avis en ligne (e-commerce, plateformes).
- Lecture manuelle impossible à grande échelle.
- NLP + ML permettent d'automatiser la classification.
- Mais : quel algorithme classique choisir sous contraintes ?
- Enjeux : scientifiques, techniques et économiques.

## Question principale

Parmi Naive Bayes, Régression Logistique, SVM et Random Forest, quel modèle offre les meilleures performances pour classer des avis (TF-IDF) en positif / négatif ?

## Sous-questions

- Effet du prétraitement NLP ?
- Avantages / limites de chaque modèle ?
- Meilleur compromis précision / rapidité / simplicité ?

# Step 2 — Revue de littérature & cadre théorique

STEP 2

## S1 · Revue systématique

Mao et al. (2024)

Cartographie des méthodes, applications et défis de l'analyse de sentiments.

## S2 · Papier tutoriel

Jurafsky & Martin (2023)

Fondements NLP : prétraitement, TF-IDF, classification de texte.

## S3 · Article original

Puh & Bagic Babac (2023)

Benchmark ML sur avis réels : SVM  $\approx$  80 %, NB  $\approx$  73 % (TF-IDF).

# Step 3 — Hypothèses de recherche (Si... alors... parce

STEP 3

H1

**SVM bat NB, LR et RF en F1**

Parce que

SVM adapté aux espaces TF-IDF haute dimension.

H2

**Le prétraitement NLP améliore tous les modèles**

Parce que

Moins de bruit → TF-IDF plus discriminant.

H3


**LR = meilleur compromis perf / temps / simplicité**

Parce que

Déploiement léger (SmartReview Lite).

# Step 4 — Plan expérimental (roadmap)

STEP 4



# Step 5 — Collecte & expérimentation

STEP 5

## Protocole exécuté

- Dataset : IMDb 50K (Maas et al., 2011).
- Split : 80 % train / 20 % test, stratifié, seed=42.
- 2 conditions : avec / sans prétraitement NLP (H2).
- Vectorisation : TF-IDF max\_features=5000, ngram=(1,2).
- 4 modèles scikit-learn entraînés sur le même split.
- Sorties : métriques CSV/JSON, figures, modèles .joblib.


## Stack technique

- Python · pandas · scikit-learn · NLTK
- matplotlib / seaborn (figures)
- joblib (sauvegarde des pipelines)
- Streamlit (démonstration interactive)
- Reproductibilité : même seed → mêmes scores
- Code : src/train\_evaluate.py

# Step 6 — Résultats principaux (avec NLP)

STEP 6

| Modèle              | Accuracy | F1    | Temps  |
|---------------------|----------|-------|--------|
| Logistic Regression | 88.71 %  | 0.889 | 1.8 s  |
| SVM (LinearSVC)     | 88.39 %  | 0.885 | 1.2 s  |
| Naive Bayes         | 85.98 %  | 0.863 | 0.05 s |
| Random Forest       | 85.15 %  | 0.852 | 77 s   |





# Validation des hypothèses H1 · H2 · H3

ANALYSE

H1

Nuancée

SVM ne domine pas : LR meilleur F1 (0.889 vs 0.885). Écart faible mais clair.

H2

Partielle

NLP améliore 2/4 modèles seulement (NB, RF). LR et SVM légèrement baissent.

H3

Confirmée

LR maximise le compromis F1 / temps / simplicité → choix SmartReview Lite.

En recherche : nuancer / réfuter une hypothèse est aussi valide que la confirmer.

# Discussion — Apports, limites & menaces à la validité

CRITIQUE

## Apports

- Benchmark reproductible 4 modèles
- Ablation NLP (design A/B)
- Critère multi-objectif (F1×temps)
- Artefact déployable (Streamlit)

## Limites

- Domaine cinéma uniquement
- Anglais seulement
- TF-IDF : ironie / sarcasme
- Hyperparamètres simples

## Validité

- Externe : transfert domaine ?
- Construit : features bag-of-words
- Interne : pas de grid-search
- Conclusion :  $\Delta$  LR-SVM petit

# Step 7 — Publication & dissémination

STEP 7

## Manuscript IEEE

Article 4 pages (IEEEtran) — méthode, résultats, figures Step 6.

## Canal choisi

IEEE ICMLA — actes IEEE Xplore · Scopus · DBLP.

## Audit prédateurs

ICMLA / IEEE absents de The Predatory Journals List → choix sûr.

## Dissémination

Code + modèles + Streamlit Lite + dossier livraison/.

# Conclusion & perspectives

FIN

## Verdict

- Déployer Logistic Regression pour SmartReview Lite.
- Cycle Steps 1→7 complété : problématique → publication.
- Hypothèses testées avec transparence scientifique.
- Artefacts prêts : PDF IEEE, fiche canal, code, démo.

## Perspectives

- Corpus multi-domaines (Amazon, hôtels...)
- Embeddings / DistilBERT sous contrainte budget
- Optimisation d'hyperparamètres
- Explainability : LIME / SHAP

# Merci — Questions ?

SmartReview · AIDI Omaïma & ELMOUSSAOUI Fatima · Prof. M. EL HAJJI