

SmartReview : Machine Learning for Customer Review Analysis

INFORMATIONS GÉNÉRALES

- **Titre du sujet** : SmartReview : Analyse automatique des avis clients par Machine Learning
- **Domaine** : Intelligence Artificielle – Traitement Automatique du Langage Naturel (NLP)
- **Niveau** : Master BD & IA
- **Réalisé par** : AIDI Omaïma, ELMOUSSAOUI Fatima

MOTS-CLÉS

Machine Learning • NLP • Analyse de sentiments • Classification de texte • TF-IDF • Naive Bayes
• Régression Logistique • SVM • Random Forest • Avis clients

1. CONTEXTE

L'essor des plateformes numériques a engendré une production massive d'avis clients. Aujourd'hui, « *millions of people write their opinions, suggestions and views about accommodation, services, and much more on various websites* » (Puh & Bagic Babac, 2023), au point que le nombre total d'avis sur TripAdvisor a dépassé **884 millions en 2020** (Puh & Bagic Babac, 2023). Face à ce volume, « *it is impossible for humans to read and analyze all these reviews on their own* » (Puh & Bagic Babac, 2023), d'où la nécessité d'automatiser cette tâche.

L'analyse de sentiment — définie comme « *a technique used by natural language processing to identify and extract information in data* » (Puh & Bagic Babac, 2023) — répond à ce besoin. Elle permet de classer automatiquement les avis en opinions positives, négatives ou neutres, offrant ainsi aux entreprises une capacité d'analyse rapide et à grande échelle. Parmi les approches disponibles, le Machine Learning classique occupe une place centrale : « *SVM is viewed as the most appropriate for sentiment analysis* » (Singh & Jaiswal, 2023). Des architectures de Deep Learning comme BiLSTM ont également montré des performances élevées, atteignant **89 % d'accuracy** contre **80 % pour SVM** sur des avis clients réels (Puh & Bagic Babac, 2023).

2. PROBLÉMATIQUE

2.1. LE PROBLÈME :

Bien que plusieurs algorithmes de Machine Learning aient été proposés pour automatiser l'analyse de sentiment, « most of the research is limited to positive/negative classification » (Puh & Bagic Babac, 2023). De plus, « the studies that test the performance of sentiment analysis are rare » (Puh & Bagic Babac, 2023), ce qui rend difficile l'identification de l'algorithme le plus adapté selon le contexte applicatif.

Par ailleurs, si les approches Deep Learning offrent de meilleures performances, « a method that is easy, versatile, and practicable, should be offered as opposed to existing machine learning methods, and more work should be put into improving the algorithms' performance » (Singh & Jaiswal, 2023).

2.2. ENJEUX DE LA RECHERCHE

Enjeux scientifiques

- Comprendre l'efficacité des algorithmes de Machine Learning appliqués à l'analyse des sentiments
- Évaluer l'impact de la représentation TF-IDF sur la classification des textes

Enjeux techniques

- Mettre en œuvre un pipeline complet de traitement de données textuelles
- Comparer plusieurs techniques de classification sur un même jeu de données

Enjeux économiques

- Réduire le temps et le coût d'analyse des avis clients
- Aider les entreprises à exploiter efficacement les retours de leurs consommateurs

2.3. QUESTION DE RECHERCHE

Question principale

Quel algorithme de Machine Learning, parmi Naive Bayes, Régression Logistique, SVM et Random Forest, offre les meilleures performances pour la classification automatique des avis clients en sentiments positifs ou négatifs après une représentation TF-IDF ?

Sous-questions

- Comment le prétraitement des données textuelles influence-t-il les performances des modèles ?
- Quels sont les avantages et les limites de chaque algorithme dans le contexte de l'analyse de sentiment ?
- Quel modèle offre le meilleur compromis entre précision, rapidité d'exécution et simplicité d'implémentation ?

3. OBJECTIF GÉNÉRAL

Développer un système d'analyse automatique des sentiments basé sur des techniques de Traitement Automatique du Langage Naturel (NLP) et comparer expérimentalement les performances de plusieurs algorithmes de Machine Learning pour la classification des avis clients.

4. OBJECTIFS SPÉCIFIQUES

1. Collecter et préparer un jeu de données d'avis clients annotés (IMDb Reviews ou Amazon Reviews)
2. Prétraiter les données textuelles : nettoyage, tokenisation, suppression des mots vides et lemmatisation
3. Transformer les textes en représentations numériques à l'aide de la méthode TF-IDF
4. Mettre en œuvre et entraîner les modèles suivants :
 - Naive Bayes
 - Régression Logistique
 - Support Vector Machine (SVM)
 - Random Forest
5. Évaluer les performances des modèles à l'aide des métriques Accuracy, Precision, Recall et F1-score
6. Comparer les résultats obtenus afin d'identifier le modèle le plus performant
7. Développer une application Streamlit permettant de tester la classification des avis de manière interactive

5. HYPOTHÈSES DE RECHERCHE

H1

La Régression Logistique et le SVM obtiendront de meilleures performances que Naive Bayes et Random Forest pour la classification des avis clients.

H2

La représentation TF-IDF permettra d'améliorer la qualité de la classification en mettant en évidence les termes les plus significatifs.

H3

Les algorithmes classiques de Machine Learning sont capables d'obtenir des résultats satisfaisants pour l'analyse des sentiments tout en nécessitant moins de ressources que les approches plus complexes.

6. MÉTHODOLOGIE ENVISAGÉE

1. Revue de littérature

Étude approfondie des travaux scientifiques portant sur l'analyse des sentiments, le NLP et les techniques de classification textuelle, en s'appuyant sur trois sources complémentaires : la revue systématique de Mao et al. (2024), le manuel de référence Jurafsky & Martin (2023), et l'article original de Puh & Bagic Babac (2023).

2. Sélection des données

Choix d'un jeu de données public contenant des avis clients annotés (IMDb Reviews ou Amazon Reviews) de grande taille pour garantir la représentativité des résultats.

3. Prétraitement des données

- Conversion en minuscules, suppression de la ponctuation et des caractères spéciaux
- Tokenisation, suppression des mots vides (stopwords), lemmatisation (Jurafsky & Martin, 2023)

4. Extraction des caractéristiques

Transformation des textes en vecteurs numériques par TF-IDF (Puh & Bagic Babac, 2023 ; Jurafsky & Martin, 2023).

5. Entraînement des modèles

- Naive Bayes | Régression Logistique | SVM | Random Forest

6. Évaluation des performances

- Métriques : Accuracy, Precision, Recall, F1-score, Matrice de confusion, Temps d'exécution (Puh & Bagic Babac, 2023)
- Comparaison avec les benchmarks de la littérature

7. Analyse comparative

Identification du modèle offrant le meilleur compromis performance / rapidité / simplicité.

8. Développement de l'application

Application : saisie d'avis, prédiction automatique, visualisation des résultats et des performances du modèle retenu.

7. RÉSULTATS ATTENDUS

- Mise en place d'un pipeline complet d'analyse de sentiments
- Comparaison expérimentale de quatre algorithmes de Machine Learning
- Identification du modèle le plus performant pour la classification des avis clients
- Développement d'une application interactive de démonstration sous Streamlit
- Formulation de recommandations sur le choix des modèles pour l'analyse automatique des avis clients

Conclusion

Cette fiche problématique détaille le cadre de recherche pour le projet SmartReview . Elle met en évidence la pertinence de l'analyse automatique des avis clients, la nécessité de comparer différentes méthodes de Machine Learning et définit clairement les objectifs, hypothèses et méthodologie envisagés. Les résultats attendus visent à fournir une solution pratique et scientifiquement fondée pour l'exploitation des retours clients.