

Hypothèses de recherche

H1 Hypothèse 1

Si on utilise SVM avec représentation TF-IDF pour classifier des avis clients, **alors** il surpassera Naive Bayes, Random Forest et la Régression Logistique, **parce que** SVM est l'algorithme le plus adapté à la classification de texte dans des espaces vectoriels de grande dimension. (Singh & Jaiswal, 2023 ; Puh & Bagic Babac, 2023)

Variable indépendante

Algorithme utilisé (NB / LR / SVM / RF)

Variable dépendante

Accuracy, Precision, Recall, F1-score

Justification

Puh & Bagic Babac (2023) confirment que SVM atteint 80 % d'accuracy sur des avis clients réels avec TF-IDF, contre 73 % pour Naive Bayes.

Comment tester ?

Entraîner les 4 modèles sur un même dataset (IMDb / Amazon). Comparer les métriques — Méthode : Benchmarking.

H2 Hypothèse 2

Si on applique un prétraitement NLP complet (tokenisation, stopwords, lemmatisation), **alors** les performances de tous les modèles s'amélioreront, **parce que** la suppression du bruit textuel permet d'obtenir une représentation TF-IDF plus discriminante. (Jurafsky & Martin, 2023)

Variable indépendante

Présence ou absence de prétraitement NLP

Variable dépendante

Qualité TF-IDF / performances des modèles

Justification

Le prétraitement conditionne directement la qualité des features et la capacité des classifieurs à distinguer un avis positif d'un négatif.

Comment tester ?

Comparer les métriques avec et sans prétraitement sur le même corpus — Méthode : Expérimentation comparative.

H3 Hypothèse 3

Si on évalue les modèles selon plusieurs critères simultanément, **alors** la Régression Logistique offrira le meilleur compromis entre performance, rapidité et simplicité, **parce que** elle obtient les meilleurs résultats parmi les classifieurs ML classiques tout en restant simple à implémenter. (Singh & Jaiswal, 2023)

Variable indépendante

Algorithme de classification choisi

Variable dépendante

Compromis performance / temps d'exécution / complexité

Justification

Dans un contexte aux ressources limitées, un modèle interprétable comme LR peut être plus adapté qu'un SVM malgré une accuracy légèrement inférieure.

Comment tester ?

Mesurer accuracy + temps d'exécution pour chaque modèle — Méthode : Benchmarking multi-critères.

Mise à jour des questions de recherche

Quel algorithme obtient les meilleures métriques de classification sur un même corpus d'avis clients ?

→ H1

Dans quelle mesure le prétraitement NLP améliore-t-il les performances des modèles ?

→ H2

Quel modèle offre le meilleur compromis entre performance, temps d'exécution et simplicité ?

→ H3