

# Step 5 : Expérimentation et Collecte de données

SmartReview : Machine Learning for Customer Review Analysis

Niveau

Auteurs

Encadrement

Année académique

Master Big Data & IA — Méthodologie de recherche

AIDI Oaima · ELMOUSSAOUI Fatima

Prof. M. EL HAJJI

2025–2026

## 1. Objectif de l'étape

Cette étape opérationnalise le protocole expérimental défini au Step 4. Elle consiste à collecter le dataset IMDb 50K, appliquer le pipeline NLP, entraîner les quatre classifieurs (Naive Bayes, Régression Logistique, SVM, Random Forest) et produire les métriques nécessaires à la validation des hypothèses H1, H2 et H3. Conformément au cours, c'est le moment du « Doing it! » : le plan conçu au Step 4 est ici réellement exécuté, testé, et confirmé par répétition (re-test).

## 2. Collecte et description des données

**Source** : IMDb Movie Reviews (Maas et al., 2011) — corpus ACL / équivalent Kaggle IMDB Dataset of 50K Movie Reviews (Lakshminpathi N). Le jeu contient 50 000 avis annotés en polarité binaire (positif / négatif), équilibré (25 000 / 25 000), ce qui limite le biais de classe.

**Justification du choix** : dataset public, reproductible, largement utilisé comme benchmark en analyse de sentiments (Puh & Bagic Babac, 2023 ; Mao et al., 2024). Il permet une comparaison directe avec la littérature.

| Indicateur          | Valeur                  |
|---------------------|-------------------------|
| Nombre total d'avis | 50 000                  |
| Avis positifs       | 25 000 (50 %)           |
| Avis négatifs       | 25 000 (50 %)           |
| Split train / test  | 80 % / 20 % (stratifié) |
| random_state        | 42                      |
| Langue              | Anglais                 |




Figure 1 — Distribution des classes et longueur des avis

Lecture de la Figure 1 : le graphique de gauche confirme visuellement l'équilibre parfait des classes (25 000 avis positifs, 25 000 négatifs). Le graphique de droite montre que la majorité des avis se situe entre 500 et 2000 caractères, avec une distribution asymétrique à droite (quelques avis longs jusqu'à environ 14 000 caractères) — aucune anomalie détectée avant l'entraînement.

## 3. Schéma d'architecture du pipeline

Le schéma ci-dessous illustre l'enchaînement complet des étapes du pipeline, tel que planifié au Step 4 et exécuté au Step 5 :

#### Architecture du pipeline SmartReview Lite — Step 5




Figure 2 — Architecture du pipeline SmartReview Lite

Chaque bloc correspond à un module du code (cf. Section 8 — Reproductibilité et artefacts) : le dataset brut est nettoyé par le module de prétraitement NLP, transformé en vecteurs numériques par TF-IDF, puis utilisé pour entraîner en parallèle les 4 modèles sur les mêmes données. Chaque modèle est évalué avec les mêmes métriques, et une boucle de re-test (cross-validation 5-fold) vient confirmer la robustesse des scores avant leur restitution dans le dashboard Streamlit.

## 4. Pipeline d'implémentation

### 4.1 Prétraitement NLP

Conformément à Jurafsky & Martin (2023), deux conditions sont implémentées pour tester H2 :

- Avec prétraitement : minuscules → suppression HTML/ponctuation → tokenisation → stopwords anglais → lemmatisation (WordNet).
- Sans prétraitement : nettoyage minimal uniquement (minuscules + caractères spéciaux).

### 4.2 Vectorisation TF-IDF

TfidfVectorizer (scikit-learn) avec max\_features=5000 et ngram\_range=(1,2), paramètres alignés sur le plan expérimental et sur les pratiques rapportées par Puh & Bagic Babac (2023).

### 4.3 Modèles entraînés

| Modèle                | Implémentation         | Paramètres clés                 |
|-----------------------|------------------------|---------------------------------|
| Naive Bayes           | MultinomialNB          | priors empiriques (défaut)      |
| Régression Logistique | LogisticRegression     | solver=liblinear, max_iter=1000 |
| SVM                   | LinearSVC              | max_iter=5000, random_state=42  |
| Random Forest         | RandomForestClassifier | n_estimators=100, n_jobs=-1     |

## 5. Résultats bruts de l'expérimentation

Le tableau ci-dessous présente l'ensemble des métriques mesurées sur le jeu de test (Accuracy, Precision, Recall, F1) ainsi que les temps d'exécution et la validation croisée 5-fold (F1), pour les deux conditions testées.

Tableau 1 — Métriques avec prétraitement NLP (condition principale)

| Modèle              | Acc    | Prec   | Rec    | F1     | Temps (s) | CV-F1 $\pm \sigma$ |
|---------------------|--------|--------|--------|--------|-----------|--------------------|
| Naive Bayes         | 0.8598 | 0.8461 | 0.8796 | 0.8625 | 0.05      | 0.860 $\pm$ 0.003  |
| Logistic Regression | 0.8871 | 0.8747 | 0.9036 | 0.8889 | 1.84      | 0.892 $\pm$ 0.002  |
| SVM (LinearSVC)     | 0.8839 | 0.8754 | 0.8952 | 0.8852 | 1.16      | 0.882 $\pm$ 0.003  |
| Random Forest       | 0.8515 | 0.8507 | 0.8526 | 0.8517 | 77.37     | 0.850 $\pm$ 0.002  |

Tableau 2 — Métriques sans prétraitement NLP (condition contrôle H2)

| Modèle              | Acc    | Prec   | Rec    | F1     | Temps (s) | CV-F1 ± σ   |
|---------------------|--------|--------|--------|--------|-----------|-------------|
| Naive Bayes         | 0.8559 | 0.8449 | 0.8718 | 0.8582 | 0.08      | 0.861±0.002 |
| Logistic Regression | 0.8934 | 0.8840 | 0.9056 | 0.8947 | 3.29      | 0.894±0.004 |
| SVM (LinearSVC)     | 0.8886 | 0.8831 | 0.8958 | 0.8894 | 1.68      | 0.890±0.003 |
| Random Forest       | 0.8500 | 0.8487 | 0.8518 | 0.8503 | 102.49    | 0.846±0.003 |




Figure 3 — Comparaison des métriques (avec prétraitement)

Lecture des résultats : avec prétraitement, la Régression Logistique obtient le meilleur F1 (0.889), suivie de très près par SVM (0.885). Effet du prétraitement (test H2) : Naive Bayes et Random Forest s'améliorent légèrement avec le prétraitement (+0.0043 et +0.0014 en F1), tandis que Logistic Regression et SVM obtiennent un F1 légèrement supérieur sans prétraitement (−0.0058 et −0.0042). Ce résultat contre-intuitif nuance H2 et sera discuté en profondeur au Step 6.

Statut préliminaire des hypothèses (détail complet en Step 6) :

| Hyp. | Énoncé                                                   | Statut                                                               |
|------|----------------------------------------------------------|----------------------------------------------------------------------|
| H1   | SVM bat NB, LR et RF en F1-score                         | Nuancée — LR légèrement devant (F1=0.889 vs 0.885)                   |
| H2   | Le prétraitement NLP améliore tous les modèles           | Partielle — NB et RF s'améliorent, LR et SVM se dégradent légèrement |
| H3   | LR = meilleur compromis performance / temps / simplicité | Confirmée                                                            |

## 6. Protocole de re-test (robustesse)

Activité C — Robustesse : conformément à l'exigence du cours ("confirm results by retesting"), les résultats n'ont pas été acceptés sur la base d'un seul run.

| Paramètre           | Valeur / Méthode                                                               |
|---------------------|--------------------------------------------------------------------------------|
| Split initial       | 80 % train / 20 % test, stratifié, random_state = 42                           |
| Validation croisée  | 5-fold cross-validation, appliquée aux 4 modèles, sur les deux conditions      |
| Objectif du re-test | Vérifier que les scores ne sont pas dus au hasard d'un split particulier       |
| Reproductibilité    | random_state fixé à 42 dans tout le pipeline ; dataset public ; code versionné |

Les écarts-types obtenus ( $\sigma$  compris entre 0.002 et 0.004, cf. Tableaux 1 et 2) sont faibles au regard des écarts de F1 observés entre modèles (jusqu'à 0.04), ce qui confirme que le classement des modèles (LR ≈ SVM > NB > RF) n'est pas un artefact du hasard lié à un split particulier, mais un résultat statistiquement robuste.

## 7. Note éthique

| Axe                             | Constat                                                                                                                                                       |
|---------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Confidentialité / anonymisation | Dataset public (Stanford acllmbd / Kaggle), avis de films librement publiés — aucune donnée personnelle identifiable.                                         |
| Équilibre des classes           | 25 000 / 25 000 — classes parfaitement équilibrées, vérifiées avant entraînement (cf. Figure 1).                                                              |
| Biais discriminatoires          | Aucune variable sensible utilisée : classification basée uniquement sur le contenu textuel (TF-IDF).<br>Limite : corpus anglais et domaine cinéma uniquement. |
| Transparence                    | Limites déclarées explicitement : TF-IDF ne capture pas bien l'ironie/le sarcasme, hyperparamètres non exhaustivement optimisés.                              |

## 8. Reproductibilité et artefacts

- Code : `src/preprocess.py`, `src/train_evaluate.py`, `app/streamlit_app.py`
- Résultats : `results/metrics_all.csv`, matrices de confusion, figures
- Modèles sérialisés : `models/*.joblib` (pipeline Streamlit inclus)
- Split stratifié, `random_state=42`, CV 5-fold → reproductibilité garantie.

## 9. Conclusion du Step 5

Les données ont été collectées, le protocole exécuté intégralement (2 conditions × 4 modèles, avec re-test par cross-validation) et les métriques produites et vérifiées pour leur robustesse statistique. L'interprétation scientifique complète et la validation formelle des hypothèses H1, H2 et H3 sont développées au Step 6.